

第3章 传统自然语言 处理分析

六、隐马尔柯夫模型



6.1 马尔柯夫模型

6.1 马尔柯夫模型

□马尔可夫模型描述

存在一类重要的随机过程：如果一个系统有 N 个状态 S_1, S_2, \dots, S_N ，随着时间的推移，该系统从某一状态转移到另一状态。如果用 q_t 表示系统在时间 t 的状态变量，那么， t 时刻的状态取值为 S_j ($1 \leq j \leq N$) 的概率取决于前 $t-1$ 个时刻 ($1, 2, \dots, t-1$) 的状态，该概率为：

$$P(q_t = S_j \mid q_{t-1} = S_i, q_{t-2} = S_k, \dots)$$

6.1 马尔柯夫模型

◆ 假设1:

如果在特定情况下，系统在时间 t 的状态只与其在时间 $t-1$ 的状态相关，则该系统构成一个离散的一阶马尔柯夫链：

$$P(q_t = S_j \mid q_{t-1} = S_i, q_{t-2} = S_k, \dots) = P(q_t = S_j \mid q_{t-1} = S_i) \dots (6.1)$$

6.1 马尔柯夫模型

◆ 假设2:

如果只考虑公式(6.1)独立于时间 t 的随机过程，即所谓的不动性假设，状态与时间无关，那么：

$$P(q_t = S_j | q_{t-1} = S_i) = a_{ij}, \quad 1 \leq i, j \leq N \quad \dots (6.2)$$

该随机过程称为马尔柯夫模型(Markov Model)。

6.1 马尔柯夫模型

在马尔柯夫模型中，状态转移概率 a_{ij} 必须满足下列条件：

$$a_{ij} \geq 0 \quad \dots (6.3)$$


$$\sum_{j=1}^N a_{ij} = 1 \quad \dots (6.4)$$

马尔柯夫模型又可分为随机有限状态自动机，该有限状态自动机的每一个状态转换过程都有一个相应的概率，该概率表示自动机采用这一状态转换的可能性。

6.1 马尔柯夫模型

◆ 马尔柯夫链可以表示成状态图（转移弧上有概率的非确定的有限状态自动机）

- 零概率的转移弧省略。
- 每个节点上所有发出弧的概率之和等于1。




6.1 马尔柯夫模型

状态序列 S_1, \dots, S_T 的概率:

$$\begin{aligned} P(S_1, \dots, S_T) &= P(S_1)P(S_2 | S_1)P(S_3 | S_1, S_2) \cdots P(S_T | S_1, \dots, S_{T-1}) \\ &= P(S_1)P(S_2 | S_1)P(S_3 | S_2) \cdots P(S_T | S_{T-1}) \\ &= \pi_{S_1} \prod_{t=1}^{T-1} a_{S_t S_{t+1}} \quad \dots (6.5) \end{aligned}$$

其中, $\pi_i = P(q_1 = S_i)$, 为初始状态的概率。

6.1 马尔柯夫模型



$$\begin{aligned}
 P(t, i, p) &= P(S_1 = t)P(S_2 = i | S_1 = t)P(S_3 = p | S_2 = i) \\
 &= 1.0 \times 0.3 \times 0.6 \\
 &= 0.18
 \end{aligned}$$

6.2 隐马尔柯夫模型


6.2 隐马尔柯夫模型

□ 隐马尔柯夫模型 (Hidden Markov Model, HMM)

描写：该模型是一个双重随机过程，我们不知道具体的状态序列，只知道状态转移的概率，即模型的状态转换过程是不可观察的（隐蔽的），而可观察事件的随机过程是隐蔽状态转换过程的随机函数。

6.2 隐马尔柯夫模型

例如： N 个袋子，每个袋子中有 M 种不同颜色的球。
一实验员根据某一概率分布选择一个袋子，然后根据袋子中不同颜色球的概率分布随机取出一个球，并报告该球的颜色。对局外人：可观察的过程是不同颜色球的序列，而袋子的序列是不可观察的。每只袋子对应 HMM 中的状态；球的颜色对应于 HMM 中的状态的输出。



6.2 隐马尔柯夫模型

□ HMM 的组成

1. 模型中的状态数为 N (袋子的数量)
2. 从每一个状态可能输出的不同的符号数 M
(不同颜色球的数目)

6.2 隐马尔柯夫模型

3. 状态转移概率矩阵 $A = a_{ij}$ (a_{ij} 为实验员从一只袋子(状态 S_i) 转向另一只袋子(状态 S_j) 取球的概率)。其中

$$\left\{ \begin{array}{l} a_{ij} = P(q_{t+1} = S_j | q_t = S_i), \quad 1 \leq i, j \leq N \\ a_{ij} \geq 0 \\ \sum_{j=1}^N a_{ij} = 1 \end{array} \right. \quad \dots (6.6)$$

6.2 隐马尔柯夫模型

4. 从状态 S_j 观察到某一特定符号 v_k 的概率分布矩阵为:

$$B=b_j(k)$$

其中, $b_j(k)$ 为实验员从第 j 个袋子中取出第 k 种颜色的球的概率。那么,

$$\left\{ \begin{array}{l} b_j(k) = P(O_t = v_k \mid q_t = S_j), \quad 1 \leq j \leq N, \quad 1 \leq k \leq M \\ b_j(k) \geq 0 \\ \sum_{k=1}^M b_j(k) = 1 \end{array} \right. \quad \dots (6.7)$$

6.2 隐马尔柯夫模型

5. 初始状态的概率分布为: $\pi = \pi_i$, 其中,

$$\left\{ \begin{array}{l} \pi_i = P(q_1 = S_i), \quad 1 \leq i \leq N \\ \pi_i \geq 0 \\ \sum_{i=1}^N \pi_i = 1 \end{array} \right. \quad \dots (6.8)$$

为了方便, 一般将 **HMM** 记为: $\mu = (A, B, \pi)$

或者 $\mu = (S, O, A, B, \pi)$ 用以指出模型的参数集合。

6.2 隐马尔柯夫模型

□ 给定HMM求观察序列

给定模型 $\mu = (A, B, \pi)$, 产生观察序列

$$\mathbf{O} = \mathbf{O}_1 \mathbf{O}_2 \cdots \mathbf{O}_T :$$

- (1) 令 $t=1$;
- (2) 根据初始状态分布 $\pi = \pi_i$ 选择初始状态 $q_1 = S_i$;
- (3) 根据状态 S_i 的输出概率分布 $b_i(k)$, 输出 $O_t = v_k$;
- (4) 根据状态转移概率 a_{ij} , 转移到新状态 $q_{t+1} = S_j$;
- (5) $t = t+1$, 如果 $t < T$, 重复步骤 (3) (4), 否则结束。

6.2 隐马尔柯夫模型

□ HMM 中的三个问题

- (1) 在给定模型 $\mu = (A, B, \pi)$ 和观察序列 $\mathbf{O} = O_1 O_2 \cdots O_T$ 的情况下，怎样快速计算概率 $P(\mathbf{O} | \mu)$?
- (2) 在给定模型 $\mu = (A, B, \pi)$ 和观察序列 $\mathbf{O} = O_1 O_2 \cdots O_T$ 的情况下，如何选择在一定意义下“最优”的状态序列 $\mathbf{Q} = q_1 q_2 \cdots q_T$ 使得该状态序列“最好地解释”观察序列？

6.2 隐马尔柯夫模型

(3) 给定一个观察序列 $O=O_1O_2...O_T$ ，如何根据最大似然估计来求模型的参数值？即如何调节模型 $\mu=(A,B,\pi)$ 的参数，使得 $P(O|\mu)$ 最大？



6.3 前向算法

6.3 前向算法

□问题1：快速计算观察序列概率 $P(O | \mu)$

给定模型 $\mu = (A, B, \pi)$ 和观察序列 $O = O_1 O_2 \dots O_T$,
快速计算 $P(O | \mu)$:


对于给定的状态序列 $Q = q_1 q_2 \dots q_T$

$$P(O | \mu) = \sum_Q P(O, Q | \mu) = \sum_Q P(Q | \mu) P(O | Q, \mu) \quad \dots (6.9)$$

$$P(Q | \mu) = \pi_{q_1} a_{q_1 q_2} a_{q_2 q_3} \dots a_{q_{t-1} q_T} \quad \dots (6.10)$$

$$P(O | Q, \mu) = b_{q_1}(O_1) \cdot b_{q_2}(O_2) \dots b_{q_T}(O_T) \quad \dots (6.11)$$

6.3 前向算法



• 困难:

如果模型 $\mu=(A, B, \pi)$ 有 N 个不同的状态, 时间长度为 T , 那么有 N^T 个可能的状态序列, 搜索路径成指数级组合爆炸。

6.3 前向算法

◆ 解决办法：动态规划

前向算法(The forward procedure)

◆ 基本思想：定义前向变量 $\alpha_t(i)$ ：

$$\alpha_t(i) = P(O_1 O_2 \cdots O_t, \underline{q_t} = S_i \mid \mu) \quad \dots(6.12)$$

如果可以高效地计算 $\alpha_t(i)$ ，就可以高效地求得

$P(O \mid \mu)$ 。

6.3 前向算法

因为 $P(O|\mu)$ 是在到达状态 q_T 时观察到序列 $O = O_1 O_2 \dots O_T$ 的概率(所有可能的概率之和):


$$\begin{aligned} P(O | \mu) &= \sum_{S_i} P(O_1 O_2 \dots O_T, q_T = S_i | \mu) \\ &= \sum_{i=1}^N \alpha_T(i) \end{aligned} \quad \dots (6.13)$$

6.3 前向算法

动态规划计算 $\alpha_t(i)$ ：在时间 $t+1$ 的前向变量可以根据时间 t 的前向变量 $\alpha_t(1), \dots, \alpha_t(N)$ 的值递推计算：

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}) \quad \dots (6.14)$$

6.3 前向算法



6.3 前向算法

算法6.1: 前向算法

(1) 初始化: $\alpha_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$

(2) 循环计算:

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), \quad 1 \leq t \leq T-1$$

(3) 结束, 输出:

$$P(O | \mu) = \sum_{i=1}^N \alpha_T(i)$$

6.3 前向算法

□ 算法的时间复杂性：

每计算一个 $\alpha_t(i)$ 必须考虑从 $t-1$ 时的所有 N 个状态转移到状态 S_i 的可能性，时间复杂性为 $O(N)$ ，对应每个时刻 t ，要计算 N 个前向变量： $\alpha_t(1), \alpha_t(2), \dots, \alpha_t(N)$ ，所以，时间复杂性为： $O(N) \times N = O(N^2)$ 。又因 $t = 1, 2, \dots, T$ ，所以前向算法总的复杂性为： $O(N^2T)$ 。



6.4 后向算法

6.4 后向算法

◆后向算法 (The backward procedure)

定义后向变量 $\beta_t(i)$ 是在给定了模型 $\mu = (A, B, \pi)$ 和假定在时间 t 状态为 S_i 的条件下, 模型输出观察序列 $O_{t+1}O_{t+2}\cdots O_T$ 的概率:

$$\beta_t(i) = P(O_{t+1}O_{t+2}\cdots O_T \mid q_t = S_i, \mu) \quad \dots (6.15)$$

6.4 后向算法

与前向变量一样，运用动态规划计算后向量：

- (1) 从时刻 t 到 $t+1$ ，模型由状态 S_i 转移到状态 S_j ，并从 S_j 输出 O_{t+1} ；
- (2) 在时间 $t+1$ ，状态为 S_j 的条件下，模型输出观察序列 $O_{t+1}O_{t+2}\cdots O_T$

6.4 后向算法

第一步的概率: $a_{ij} \times b_j(O_{t+1})$

第二步的概率按后向变量的定义为: $\beta_{t+1}(j)$

于是, 有归纳关系:


$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j) \quad \dots (6.16)$$

归纳顺序: $\beta_T(x), \beta_{T-1}(x), \dots, \beta_1(x)$

(x 为 HMM 的状态)

6.4 后向算法

算法的图形解释：



6.4 后向算法

◆ 算法6.2: 后向算法

(1) 初始化: $\beta_T(i) = 1, 1 \leq i \leq N$

(2) 循环计算:

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), \quad T-1 \geq t \geq 1, \quad 1 \leq i \leq N$$

(3) 输出结果: $P(O | \mu) = \sum_{i=1}^N \pi_i \beta_1(i)$

算法的时间复杂性: $O(N^2T)$

A decorative graphic in the top-left corner consisting of a black crosshair. The horizontal bar is thick and grey, extending across the top of the slide. The vertical line is thin and black. At the intersection, there are three overlapping squares: a blue one in the top-left, a red one in the bottom-left, and a yellow one in the bottom-right.

6.5 Viterbi 搜索算法

6.5 Viterbi 搜索算法

□问题2—如何发现“最优”状态序列
能够“最好地解释”观察序列

解释不是唯一的，关键在于如何理解
“最优”的状态序列？一种解释是：状态序列中的每个状态都单独地具有概率，
即：对于每个时刻 t ($1 \leq t \leq T$)，寻找 q_t
使得 $P(q_t = S_i | O, \mu)$ 最大。

6.5 Viterbi 搜索算法

$$\gamma_t(i) = P(q_t = S_i | O, \mu) = \frac{P(q_t = S_i, O | \mu)}{P(O | \mu)} \quad \dots (6.17)$$

HMM 的输出序列 O ，并且在时间 t 到达状态 i 的概率。

6.5 Viterbi 搜索算法

分解过程:

(1) HMM 在时间 t 到达状态 i , 并且输出 $O_1 O_2 \dots O_t$ 根据前向变量的定义, 实现这一步的概率为: $\alpha_t(i)$ 。

(2) 从时间 t , 状态 S_i 出发, HMM 输出 $O_{t+1} O_{t+2} \dots O_T$, 根据后向变量定义, 实现这一步的概率为 $\beta_t(i)$ 。

于是:

$$P(q_t = S_i, O \mid \mu) = \alpha_t(i) \times \beta_t(i) \quad \dots (6.18)$$

6.5 Viterbi 搜索算法

而 $P(O | \mu)$ 与时间 t 的状态无关，因此：

$$P(O | \mu) = \sum_{i=1}^N \alpha_t(i) \times \beta_t(i) \quad \dots (6.19)$$

将公式(6.18)和(6.19)带入(6.17)式得：

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{\sum_{i=1}^N \alpha_t(i) \times \beta_t(i)} \quad \dots (6.20)$$


t 时刻的最优状态为： $\hat{q}_t = \arg \max_{1 \leq i \leq N} (\gamma_t(i))$

6.5 Viterbi 搜索算法

问题:

每一个状态单独最优不一定使整体的状态序列最优，可能两个最优的状态 \hat{q}_t 和 \hat{q}_{t+1} 之间的转移概率为0，即 $a_{\hat{q}_t \hat{q}_{t+1}} = 0$ 。

6.5 Viterbi 搜索算法



6.5 Viterbi 搜索算法

另一种解释：在给定模型 μ 和观察序列 O 的条件下求概率最大的状态序列：

$$\hat{Q} = \arg \max_Q P(Q | O, \mu) \quad \dots (6.21)$$

Viterbi algorithm: 动态搜索最优状态序列。

定义：Viterbi 变量 $\delta_t(i)$ 是在时间 t 时，HMM 沿着某一条路径到达 S_i ，并输出观察序列

$O_1 O_2 \dots O_t$ 的最大概率：

$$\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = S_i, O_1 O_2 \dots O_t | \mu) \quad \dots (6.22)$$

6.5 Viterbi 搜索算法

递归计算: $\delta_{t+1}(i) = \max_j [\delta_t(j) \cdot a_{ji}] \cdot b_i(O_{t+1}) \quad \dots (6.23)$

算法6.3: Viterbi 算法

(1) 初始化: $\delta_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$

概率最大的路径变量: $\psi_1(i) = 0$

(2) 递推计算:

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$

$$\psi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) \cdot a_{ij}] \cdot b_j(O_t), \quad 2 \leq t \leq T, \quad 1 \leq j \leq N$$

6.5 Viterbi 搜索算法

(3) 结束:

$$\hat{Q}_T = \arg \max_{1 \leq i \leq N} [\delta_T(i)], \quad \hat{P}(\hat{Q}_T) = \max_{1 \leq i \leq N} \delta_T(i)$$

(4) 通过回溯得到路径（状态序列）：

$$\hat{q}_t = \psi_{t+1}(\hat{q}_{t+1}), \quad t = T-1, T-2, \dots, 1$$

算法的时间复杂性： $O(N^2T)$



6.6 参数学习

6.6 参数学习

□ 问题3—模型参数学习

给定一个观察序列 $O = O_1 O_2 \dots O_T$ ，如何根据最大似然估计来求模型的参数值？即如何调节模型 $\mu = (A, B, \pi)$ 的参数，使得 $P(O|\mu)$ 最大？即估计模型中的 $\pi_i, a_{ij}, b_j(k)$ 使得观察序列 O 的概率 $P(O|\mu)$ 最大。

前向后向算法

(Baum-Welch or forward-backward procedure)

6.6 参数学习

如果产生观察序列 O 的状态 $Q = q_1q_2 \dots q_T$ 已知，
可以用最大似然估计来计算 HMM 的参数：

$$\bar{\pi}_i = \delta(q_1, S_i)$$

$$\begin{aligned} \bar{a}_{ij} &= \frac{Q \square \square \square \square q_i \square \square \square q_j \square \square \square}{Q \square \square \square \square \square \square q_i \square \square \square \square \square \square \square (\square \square q_j \square \square) \square \square \square} \\ &= \frac{\sum_{t=1}^{T-1} \delta(q_t, S_i) \times \delta(q_{t+1}, S_j)}{\sum_{t=1}^{T-1} \delta(q_t, S_i)} \quad \dots (6.24) \end{aligned}$$

其中， $\delta(x, y)$ 为克罗奈克(Kronecker)函数，当 $x=y$ 时， $\delta(x, y)=1$ ，否则 $\delta(x, y) = 0$ 。

6.6 参数学习

类似地，

$$\begin{aligned}\bar{b}_j(k) &= \frac{Q \text{中从状态 } q_j \text{ 输出符号 } v_k \text{ 的次数}}{Q \text{ 到达 } q_j \text{ 的总次数}} \\ &= \frac{\sum_{t=1}^T \delta(q_t, S_j) \times \delta(O_t, v_k)}{\sum_{t=1}^T \delta(q_t, S_j)} \quad \dots (6.25)\end{aligned}$$

其中， v_k 是模型输出符号集中的第 k 个符号。

6.6 参数学习

期望值最大化算法 (Expectation-Maximization, EM)

基本思想：初始化时随机地给模型的参数赋值 (遵循限制规则，如：从某一状态出发的转移概率总和为 1，得到模型 μ_0 ，然后可以从 μ_0 得到从某一状态转移到另一状态的期望次数，然后以期望次数代替公式中的实际次数，得到模型参数的新估计，由此得到新的模型 μ_1 ，从 μ_1 又可得到模型中隐变量的期望值，由此重新估计模型参数。循环这一过程，参数收敛于最大似然估计值。


6.6 参数学习

给定 HMM 模型 μ 和观察序列 $O = O_1 O_2 \dots O_T$,
那么, 在时间 t 位于状态 S_i , 时间 $t+1$ 位于状态 S_j 的概率:

$$\begin{aligned}\xi_t(i, j) &= P(q_t = S_i, q_{t+1} = S_j \mid O, \mu) = \frac{P(q_t = S_i, q_{t+1} = S_j, O \mid \mu)}{P(O \mid \mu)} \\&= \frac{\alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)}{P(O \mid \mu)} \\&= \frac{\alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)} \quad \dots (6.26)\end{aligned}$$

6.6 参数学习

图解搜索过程：



6.6 参数学习

那么，给定模型 μ 和观察序列 $O = O_1 O_2 \dots O_T$ ，
在时间 t 位于状态 S_i 的概率为：

$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i, j) \quad \dots (6.27)$$

由此，模型 μ 的参数可由下面的公式重新估计：

(1) q_1 为 S_i 的概率：

$$\pi_i = \gamma_1(i) \quad \dots (6.28)$$

6.6 参数学习

(2)

$$\bar{a}_{ij} = \frac{Q \text{中从状态 } q_i \text{ 转移到 } q_j \text{ 的期望次数}}{Q \text{中所有从状态 } q_i \text{ 转移到下一状态(包括 } q_j \text{ 自身)的期望次数}}$$
$$= \frac{\sum_{i=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad \dots (6.29)$$

(3)

$$\bar{b}_j(k) = \frac{Q \text{中从状态 } q_j \text{ 输出符号 } v_k \text{ 的期望次数}}{Q \text{到达 } q_j \text{ 的期望次数}}$$
$$= \frac{\sum_{t=1}^T \gamma_t(j) \times \delta(O_t, v_k)}{\sum_{t=1}^T \gamma_t(j)} \quad \dots (6.30)$$

6.6 参数学习

◆ 算法6.4: Baum-Welch 算法:

(1) 初始化: 随机地给 π_i , a_{ij} , $b_j(k)$ 赋值,

使得

$$\left\{ \begin{array}{l} \sum_{i=1}^N \pi_i = 1 \\ \sum_{j=1}^N a_{ij} = 1 \\ \sum_{k=1}^M b_i(k) = 1 \end{array} \right. \quad \begin{array}{ll} 1 \leq i \leq N & \dots (6.31) \\ 1 \leq i \leq N \end{array}$$

由此得到模型 μ_0 , 令 $i = 0$ 。

6.6 参数学习

(2) 执行 EM 算法:

E-步: 由模型 μ_i 根据公式 (6.26) 和 (6.27) 计算期望值 $\xi_t(i, j)$ 和 $\gamma_t(i)$ 。

M-步: 用E-步中所得到的期望值, 根据公式 (6.28-6.30) 重新估计 $\pi_i, a_{ij}, b_j(k)$ 得到模型 μ_{i+1} 。

循环: $i = i+1$, 重复执行 E-步和M-步, 直至 $\pi_i, a_{ij}, b_j(k)$ 的值收敛: $|\log P(O | \mu_{i+1}) - \log P(O | \mu_i)| < \varepsilon$ 。

(3) 结束算法, 获得相应的参数。

6.6 参数学习

□ HMM 使用中注意的问题

- ◆ Viterbi 算法运算中的小数连乘，出现溢出
— 对数
- ◆ Forward-Backward 算法的小数溢出
— 放大系数
— 参阅[Rabiner and Juang, 1993: pp. 365-368]
— 参阅 <http://htk.eng.cam.ac.uk/>

A decorative graphic in the top-left corner consisting of overlapping blue, red, and yellow squares with a black crosshair.

6.7 应用举例

6.7 应用举例

汉语的自动分词与词性标注问题：

自动化研究所取得的成绩

自动化/N 研究所/N 取得/V 的/X 成绩/N

自动化/N 研究/N 所/P 取得/V 的/X 成绩/N
/V

6.7 应用举例

用 HMM 来解决这一问题:

- (1) 状态转移模型
- (2) 状态到观察序列的生成模型

思路:

- (1) 汉字串(句子) 作为输入; 单词串 S_w 为状态的输出, 即观察序列 $S_w = w_1 w_2 \cdots w_n \quad (n \geq 1)$;
- (2) 词性序列 S_c 为状态序列, 每个词性标记 C_i 对应HMM中的一个状态: $S_c = c_1 c_2 \cdots c_n$ 。

6.7 应用举例

问题:

- (1) 估计模型的参数;
- (2) 对于一个给定的输入句子及其可能的输出序列 S_w 和模型 $\mu = (A, B, \pi)$, 快速计算 $P(S_w | \mu)$ 。
所有可能的 S_w 中使概率最大的解就是要找的分词结果;
- (3) 快速地选择“最优”的状态序列(词性序列)。

6.7 应用举例

假设模型中状态(词性)的数目为词性符号的个数 N ；从每个状态可能输出的不同符号(单词)的数目为词汇的个数 M 。

假设在统计意义上每个词性的概率分布只与上一个词的词性有关(即词性的二元语法)，而每个单词的概率分布只与其词性相关。那么，我们就可以通过对已分词并做了词性标注的训练语料进行统计，得到如下三个矩阵：

6.7 应用举例

- (1) 初始状态(词性)的概率分布矩阵;
- (2) 状态转移(词性到词性的转移)概率矩阵;
- (3) 从状态(词性)观察到输出符号(单词)的概率分布矩阵。

对于任何一个给定的观察值序列(单词串), 总可以通过Viterbi算法很快地得到一个可能性最大的状态值序列(词性串)。

本章小结

□ HMM 的构成:

状态数

输出符号数

初始状态的概率分布

状态转移的概率

输出概率

本章小结

□ HMM 的三个基本问题:

- 1) 快速计算给定模型的观察序列的概率
— 前向算法或后向算法
- 2) 求最优状态序列
— Viterbi 算法
- 3) HMM 中的参数估计
— Baum-Welch (前向-后向)算法

□ 模型实现中需要注意的问题: 小数溢出

习题

1. 下载 HTK (<http://htk.eng.cam.ac.uk/>), 了解相应工具的使用方法。
2. 利用HTK工具, 实现一个简单的汉语音字转换程序或汉语分词与词性标注程序。



Thanks

谢谢!